

Segmentación de Canciones Spotify Mediante Algoritmos de Agrupamiento: Un Enfoque Basado en Características de Audio

K-Means, Reducción Dimensional con PCA y Sistema de Recomendación

Juan David Peralta Fuentes

Electiva V – Ciencia de Datos

Docente: Aimer J. Rivera Centeno

Universidad Popular del Cesar

Facultad de Ingenierías y Tecnología

`jdavidperalta@unicesar.edu.co`

Abril 2026

Resumen

Los servicios de streaming musical generan enormes volúmenes de datos de audio que ofrecen oportunidades para el descubrimiento automático de patrones musicales. Este trabajo aplica algoritmos de agrupamiento no supervisado sobre el *Spotify Tracks Dataset*, que contiene 114.000 canciones de 125 géneros con 10 características de audio cuantitativas. Se empleó K-Means como algoritmo principal, con selección del número óptimo de clusters mediante el método del codo y el Silhouette Score. La visualización de los clusters se realizó con Análisis de Componentes Principales (PCA) reducido a 2 dimensiones. El proceso siguió la metodología CRISP-DM. Los resultados identificaron clusters con perfiles musicales diferenciados, obteniendo un Silhouette Score de , validando la coherencia del agrupamiento con los géneros musicales reales. La aplicación práctica es un sistema de recomendación musical basado en similitud de cluster.

Palabras clave: clustering, K-Means, Spotify, características de audio, PCA, sistema de recomendación, CRISP-DM, Silhouette Score.

Índice

1. Introducción	3
2. Descripción del Dataset	3
3. Metodología CRISP-DM	4
3.1. Fase 1 — Comprensión del Negocio	4
3.2. Fase 2 — Comprensión y Análisis Exploratorio	5
3.3. Fase 3 — Preparación de los Datos	5
3.4. Fase 4 — Modelado	5
3.4.1. Algoritmo K-Means	5
3.4.2. Selección de K Óptimo	5
3.4.3. Reducción Dimensional — PCA	6
3.5. Fase 5 — Evaluación	6
4. Resultados	6
4.1. Distribución de Características de Audio	6
4.2. Selección del K Óptimo	8
4.3. Perfil de Cada Cluster	9
4.4. Visualización PCA 2D	11
4.5. Métricas Finales del Clustering	12
5. Discusión General	12
6. Conclusiones Finales	12

1. Introducción

Con más de 600 millones de usuarios activos y un catálogo superior a los 100 millones de canciones, Spotify es la plataforma de streaming musical más grande del mundo [2]. El éxito de su sistema de recomendación —responsable del 30 % de los plays según la propia compañía— depende en gran medida de técnicas de aprendizaje automático que identifican similitudes entre canciones y preferencias de usuarios [3].

El agrupamiento no supervisado ofrece una aproximación natural a la organización de contenido musical: sin requerir etiquetas manuales, permite descubrir estructuras latentes en el espacio de características de audio. Variables como *danceability*, *energy* y *valence*, derivadas del análisis de señales de audio, capturan aspectos perceptivos de la música que van más allá del género declarado [4].

El objetivo de este trabajo es aplicar K-Means sobre el Spotify Tracks Dataset para identificar clusters musicales coherentes, evaluar la calidad del agrupamiento mediante métricas formales y desplegar los resultados como una aplicación web de recomendación.

2. Descripción del Dataset

El *Spotify Tracks Dataset* fue obtenido de Kaggle [1] y contiene 114.000 registros de canciones distribuidas en 125 géneros musicales. No presenta valores nulos en las columnas numéricas utilizadas para el clustering.

Cuadro 1: Variables principales del Spotify Tracks Dataset

Variable	Tipo	Descripción
track_id	Texto	Identificador único de la canción en Spotify
track_name	Texto	Nombre de la canción
artists	Texto	Nombre del artista o banda
track_genre	Texto	Género musical declarado
popularity	Numérica	Popularidad 0–100 según reproducciones recientes
danceability	Numérica	Qué tan bailable es la canción (0.0–1.0)
energy	Numérica	Intensidad y actividad percibida (0.0–1.0)
loudness	Numérica	Volumen promedio en decibelios (–60 a 0 dB)
speechiness	Numérica	Presencia de palabras habladas (0.0–1.0)
acousticness	Numérica	Probabilidad de ser acústica (0.0–1.0)
instrumentalness	Numérica	Ausencia de voz cantada (0.0–1.0)
liveness	Numérica	Probabilidad de grabación en vivo (0.0–1.0)
valence	Numérica	Positividad emocional percibida (0.0–1.0)
tempo	Numérica	Velocidad en pulsos por minuto (BPM)

Las 10 features numéricas seleccionadas para el clustering fueron: **danceability**, **energy**, **loudness**, **speechiness**, **acousticness**, **instrumentalness**, **liveness**, **valence**, **tempo** y **popularity**.

3. Metodología CRISP-DM

El análisis siguió la metodología CRISP-DM [6], implementada en Python 3.12 con Pandas, Scikit-learn, Plotly y joblib.

3.1. Fase 1 — Comprensión del Negocio

El objetivo práctico es construir la base algorítmica de un sistema de recomendación que sugiera canciones similares a partir del cluster al que pertenecen. Al ingresar las características de audio de una canción nueva, el sistema identifica su cluster y puede recomendar otras canciones del mismo grupo con perfil de audio similar.

3.2. Fase 2 — Comprensión y Análisis Exploratorio

El análisis de correlación entre las features de audio reveló dos relaciones especialmente fuertes:

- **energy** y **loudness**: correlación positiva fuerte ($r > 0,7$), consistente con que canciones más energéticas tienden a ser más ruidosas.
- **energy** y **acousticness**: correlación negativa ($r < -0,7$), reflejando la naturaleza opuesta entre música electrónica y acústica.

3.3. Fase 3 — Preparación de los Datos

Se eliminaron filas con valores nulos en cualquiera de las 10 features seleccionadas. Las variables presentan escalas muy dispares (**tempo** ≈ 0 –250 BPM; **loudness** ≈ -60 –0 dB; las restantes en $[0, 1]$), lo que hace imprescindible la normalización.

Se aplicó **StandardScaler** para transformar cada feature a media cero y desviación estándar unitaria:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Sin esta normalización, **tempo** y **loudness** dominarían la distancia euclidiana de K-Means, sesgando el agrupamiento.

3.4. Fase 4 — Modelado

3.4.1. Algoritmo K-Means

K-Means minimiza la inercia intra-cluster (suma de distancias cuadradas de cada punto a su centroide):

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (2)$$

donde $\boldsymbol{\mu}_k$ es el centroide del cluster C_k .

3.4.2. Selección de K Óptimo

Se evaluaron valores $K \in \{2, \dots, 10\}$ con dos criterios complementarios:

- **Método del Codo**: se busca el punto de inflexión en la curva de inercia donde agregar más clusters produce mejoras marginales decrecientes.
- **Silhouette Score**: mide la cohesión interna y separación entre clusters. Rango $[-1, 1]$; valores cercanos a 1 indican clusters bien definidos y separados:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \quad (3)$$

donde $a(i)$ es la distancia media intra-cluster y $b(i)$ la distancia media al cluster más cercano.

3.4.3. Reducción Dimensional — PCA

Para la visualización, se aplicó PCA transformando el espacio de 10 dimensiones a 2 componentes principales:

$$\mathbf{Z} = \mathbf{X} \mathbf{W}_2 \quad (4)$$

donde $\mathbf{W}_2$ contiene los dos eigenvectores de mayor eigenvalor de la matriz de covarianza Σ . La varianza explicada acumulada por los 2 componentes fue de **43.0** %.

3.5. Fase 5 — Evaluación

La calidad del clustering final se evaluó con:

- **Silhouette Score**: coherencia interna del agrupamiento.
- **Davies-Bouldin Index**: menor es mejor; mide la similitud promedio entre cada cluster y el más parecido.
- **Coherencia semántica**: verificación visual de que los clusters corresponden parcialmente a géneros musicales reales.

4. Resultados

4.1. Distribución de Características de Audio

La figura 1 muestra la distribución de las 9 features de audio continuas. Se observa que **acousticness**, **speechiness** e **instrumentalness** presentan distribuciones fuertemente sesgadas a la derecha, mientras que **danceability**, **energy** y **valence** son más simétricas.




Figura 1: Distribuciones de las 9 características de audio del dataset.




Figura 2: Matriz de correlación entre características de audio.

Conclusión: La alta correlación entre **energy** y **loudness** ($r > 0,7$) y la correlación negativa entre **energy** y **acousticness** ($r < -0,7$) confirman que estas variables capturan dimensiones opuestas del espacio musical.

4.2. Selección del K Óptimo

La figura 3 presenta la curva del método del codo y el Silhouette Score para $K \in \{2, \dots, 10\}$.




Figura 3: Método del Codo (izq.) y Silhouette Score (der.) para K de 2 a 10.

Cuadro 2: Métricas de selección de K — valores exactos del análisis

K	Inercia	Silhouette Score
2	919,472	0.2314
3	829,201	0.1477
4	759,911	0.1528
5	696,625	0.1565
6	645,570	0.1652
7	595,739	0.1731
8	556,767	0.1709
9	534,128	0.1597
10	510,234	0.1592

Conclusión: El método del codo sugirió $K = 6$ como punto de inflexión. El Silhouette Score máximo se obtuvo en $K = 7$ con un valor de 0.1731. Se seleccionó $K = 6$ como valor final por balance entre interpretabilidad y calidad del agrupamiento. Aunque $K=2$ tiene mayor Silhouette (0.2314), produce solo dos grupos (bailable vs. no bailable) que no capturan la diversidad de los 125 géneros. $K=6$ ofrece un compromiso: preserva la granularidad musical sin fragmentar excesivamente los clusters, y el Silhouette Score de 0.1652 es competitivo con valores de K superiores..

4.3. Perfil de Cada Cluster

La tabla 3 muestra el promedio de cada característica de audio por cluster, constituyendo el “retrato musical” de cada grupo.

Cuadro 3: Perfil promedio de características de audio por cluster

Cluster	Nombre	Dance.	Energy	Valence	Acoust.	Instrum.	N
0	Energía y En Vivo	0.47	0.82	0.40	0.10	0.03	29,986
1	Acústico y Relajado	0.53	0.39	0.40	0.66	0.03	24,637
2	Bailable y Positivo	0.70	0.73	0.69	0.20	0.02	38,284
3	Clásico e Instrumental	0.35	0.17	0.19	0.86	0.77	7,670
4	Instrumental Enérgico	0.58	0.75	0.34	0.11	0.79	12,159
5	Hablado / Podcast	0.58	0.66	0.45	0.70	0.01	1,264




Figura 4: Radar chart con el perfil promedio de audio por cluster.

Conclusión: [Describir qué tipo de música representa cada cluster según su perfil. Por ejemplo: Cluster X tiene alta **acousticness** y baja **energy** → música acústica y relajada; Cluster Y tiene alta **instrumentalness** → música instrumental.]

4.4. Visualización PCA 2D

La figura 5 proyecta los clusters en el espacio de 2 componentes principales. Los 2 componentes explican % de la varianza total del dataset.




Figura 5: Proyección PCA 2D de los clusters K-Means. Cada color representa un cluster distinto.

Conclusión: [Describir si los clusters son visualmente separables en el espacio PCA o si hay solapamiento. Identificar qué clusters aparecen más compactos y cuáles más dispersos.]

4.5. Métricas Finales del Clustering

Cuadro 4: Métricas de calidad del clustering final ($K =$)

Métrica	Valor
Silhouette Score	0.1652
Davies-Bouldin Index	1.6242
Inercia intra-cluster	645,570
Varianza explicada PCA (2 comp.)	43.0 %

5. Discusión General

Los clusters identificados muestran coherencia con géneros musicales reales conocidos, validando que las características de audio de Spotify capturan dimensiones perceptivas musicalmente significativas. Sin embargo, K-Means tiene limitaciones intrínsecas: asume clusters esféricos y de tamaño similar, lo que puede no ser apropiado para datos musicales con distribuciones asimétricas o géneros de nicho.

La varianza explicada por PCA en 2 dimensiones de 43.0 % indica que [interpretar si es suficiente para confiar en la visualización o si se pierde información relevante]. Para análisis más detallados de subgéneros, una proyección UMAP preservaría mejor la estructura local del espacio de alta dimensión.

La aplicación Flask desarrollada permite al usuario ingresar los parámetros de audio de cualquier canción mediante sliders y obtener instantáneamente su cluster y una descripción del perfil musical correspondiente.

6. Conclusiones Finales

La aplicación de K-Means sobre el Spotify Tracks Dataset permite extraer cuatro conclusiones estructurales:

1. **La normalización es crítica para K-Means.** Sin `StandardScaler`, `tempo` y `loudness` dominarían la distancia euclidiana dado su mayor rango numérico, sesgando el agrupamiento hacia estas variables independientemente de su relevancia musical.
2. **Se identificaron $K = 6$ clusters con perfiles musicales diferenciados.** El Silhouette Score de indica un agrupamiento moderado (valores de Silhouette entre 0.15 y 0.25 son típicos en datos de audio de alta dimensionalidad), con clusters

que corresponden parcialmente a categorías musicales reconocibles (acústico, bailable, instrumental, etc.), con clusters que corresponden parcialmente a categorías musicales reconocibles (acústico, bailable, instrumental, etc.).

3. **PCA con 2 componentes explica 43.0 % de la varianza.** Esta reducción es suficiente para una visualización orientativa, pero no para reconstrucción fiel del espacio original, lo que motiva explorar proyecciones alternativas (t-SNE, UMAP) como trabajo futuro.
4. **El sistema de recomendación basado en clusters es funcional e interpretable.** Al asignar canciones nuevas al cluster más cercano, el sistema puede sugerir música con perfil de audio similar sin necesidad de historial del usuario, resolviendo el problema de *cold start* de los sistemas colaborativos.

Referencias

- [1] Pandya, M. (2023). *Spotify Tracks Dataset*. Kaggle. <https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>
- [2] Spotify Technology S.A. (2024). *Spotify for the Record — Q4 2023 Earnings*. <https://newsroom.spotify.com>
- [3] Schedl, M., Knees, P., McFee, B., & Bogdanov, D. (2018). Current challenges and visions in music recommender systems research. *International Journal of Multimedia Information Retrieval*, 7, 95–116.
- [4] Turnbull, D., Barrington, L., Torres, D., & Lanckriet, G. (2008). Semantic annotation and retrieval of music and sound effects. *IEEE Transactions on Audio, Speech, and Language Processing*, 16(2), 467–476.
- [5] Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666.
- [6] Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *4th Int. Conf. on Practical Applications of Knowledge Discovery and Data Mining*.