

Detección de Fraude en Transacciones de Tarjeta de Crédito Mediante Técnicas de Clasificación y Aprendizaje Automático

Comparación de Modelos, Manejo de Desbalance y Despliegue Web

Juan David Peralta Fuentes

Electiva V – Ciencia de Datos

Docente: Aimer J. Rivera Centeno

Universidad Popular del Cesar

Facultad de Ingenierías y Tecnología

`jdavidperalta@unicesar.edu.co`

Abril 2026

Resumen

El fraude en transacciones con tarjetas de crédito representa una amenaza creciente para el sistema financiero global. Este trabajo presenta un pipeline completo de clasificación binaria supervisada aplicado al dataset *Credit Card Fraud Detection* de Kaggle, que contiene 284.807 transacciones de titulares europeos con un desbalance severo de clases (0,17 % de fraudes). Siguiendo la metodología CRISP-DM, se compararon cuatro algoritmos: Regresión Logística, Random Forest, XGBoost y Gradient Boosting. El desbalance se abordó con SMOTE sobre el conjunto de entrenamiento. Los resultados muestran que el mejor modelo alcanzó un ROC-AUC de **0.9841**, con un Recall de **0.8061** para la clase fraude, confirmando la viabilidad de los modelos ensemble para su integración en sistemas de detección en tiempo real.

Palabras clave: fraude, clasificación, SMOTE, XGBoost, Random Forest, desbalance de clases, CRISP-DM, ROC-AUC.

Índice

1. Introducción	2
2. Descripción del Dataset	2
3. Metodología CRISP-DM	3
3.1. Fase 1 — Comprensión del Negocio	3
3.2. Fase 2 — Comprensión de los Datos	3
3.3. Fase 3 — Preparación de los Datos	3
3.3.1. Manejo del Desbalance — SMOTE	4
3.4. Fase 4 — Modelado	4
3.4.1. Regresión Logística	4
3.4.2. Random Forest	4
3.4.3. XGBoost	4
3.4.4. Gradient Boosting	4
3.5. Fase 5 — Evaluación	5
4. Resultados	5
4.1. Análisis Exploratorio de Datos	5
4.2. Comparación de Modelos	7
4.3. Curvas ROC	7
4.4. Matriz de Confusión del Mejor Modelo	8
4.5. Variables Más Influyentes	9
5. Discusión General	10
6. Conclusiones Finales	11

1. Introducción

El fraude con tarjetas de crédito genera pérdidas millonarias a nivel mundial. Según la Nilson Report, las pérdidas globales por fraude en pagos con tarjeta superaron los 32.000 millones de dólares en 2021, con proyecciones de crecimiento sostenido [5]. La detección temprana de estas actividades es crucial para proteger tanto a los consumidores como a las instituciones financieras.

Los métodos tradicionales basados en reglas heurísticas presentan limitaciones frente a la evolución constante de las tácticas fraudulentas. El aprendizaje automático ofrece una alternativa adaptativa y escalable, capaz de identificar patrones complejos y no lineales en grandes volúmenes de datos transaccionales [2].

El principal desafío técnico de este problema es el **severo desbalance de clases**: en el dataset utilizado, apenas el 0,17 % de las transacciones son fraudes. Esto provoca que los clasificadores estándar tiendan a predecir siempre la clase mayoritaria, logrando alta exactitud pero fallando en la detección real del fraude [3].

El objetivo de este trabajo es implementar y comparar cuatro algoritmos de clasificación bajo la metodología CRISP-DM, aplicando SMOTE para el manejo del desbalance, y desplegar el modelo ganador como servicio web interactivo.

2. Descripción del Dataset

El dataset *Credit Card Fraud Detection* fue obtenido de Kaggle [1] y contiene transacciones realizadas por tarjetahabientes europeos durante septiembre de 2013. No presenta valores nulos en ninguna columna, lo que elimina la necesidad de imputación previa.

Cuadro 1: Variables principales del dataset Credit Card Fraud Detection

Variable	Tipo	Descripción
V1 – V28	Numérica	Componentes PCA (anonimizados por privacidad)
Time	Numérica	Segundos desde la primera transacción del dataset
Amount	Numérica	Monto de la transacción en euros
Class	Binaria	Variable objetivo: 0 = legítima, 1 = fraude
Time_scaled	Numérica	Time normalizado con StandardScaler
Amount_scaled	Numérica	Amount normalizado con StandardScaler

Cuadro 2: Estadísticas de la variable objetivo (Class)		
Clase	Frecuencia	Porcentaje
0 — Transacción legítima	284.315	99,83 %
1 — Transacción fraudulenta	492	0,17 %
Total	284.807	100,00 %

3. Metodología CRISP-DM

El análisis siguió la metodología *Cross-Industry Standard Process for Data Mining* (CRISP-DM) [6], estructurada en seis fases iterativas. El desarrollo se realizó en Python 3.12 sobre Google Colab, utilizando Pandas, Scikit-learn, XGBoost, imbalanced-learn y Plotly.

3.1. Fase 1 — Comprensión del Negocio

El problema se formula como clasificación binaria supervisada: dada una transacción con características $\mathbf{x} \in R^{30}$, predecir $y \in \{0, 1\}$ donde $y = 1$ indica fraude. La **métrica de negocio prioritaria** es el Recall de la clase fraude, pues un falso negativo (fraude no detectado) implica pérdida económica directa para el emisor de la tarjeta.

3.2. Fase 2 — Comprensión de los Datos

El análisis exploratorio confirmó tres hallazgos estructurales relevantes:

- El monto promedio de transacciones fraudulentas (\$122,21) es *inferior* al de legítimas (\$88,29), contrario a la intuición inicial.
- Las variables con mayor correlación (en valor absoluto) con **Class** son V_{14} ($r = -0,30$), V_{17} ($r = -0,33$) y V_{12} ($r = -0,26$).
- Las 28 componentes PCA no presentan correlación entre sí por construcción matemática, eliminando el riesgo de multicolinealidad.

3.3. Fase 3 — Preparación de los Datos

Las columnas **Time** y **Amount** (las únicas variables no transformadas por PCA) se normalizaron con **StandardScaler**. El conjunto se dividió en 80 % entrenamiento y 20 % prueba con **stratify=y** para preservar la proporción de clases.

3.3.1. Manejo del Desbalance — SMOTE

Se aplicó *Synthetic Minority Over-sampling Technique* (SMOTE) [3] **exclusivamente sobre el conjunto de entrenamiento** para evitar data leakage. SMOTE genera instancias sintéticas de la clase minoritaria interpolando entre vecinos cercanos en el espacio de características, equilibrando ambas clases antes del entrenamiento.

Cuadro 3: Distribución de clases antes y después de SMOTE (conjunto de entrenamiento)

Clase	Pre-SMOTE	Post-SMOTE
0 — Legítima	227.451	227.451
1 — Fraude	394	227.451
Total	227.845	454.902

3.4. Fase 4 — Modelado

Se entrenaron y compararon cuatro algoritmos de clasificación:

3.4.1. Regresión Logística

Modelo lineal base. Dado el vector de características $\mathbf{x}$:

$$P(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (1)$$

3.4.2. Random Forest

Ensemble de T árboles de decisión que agrega predicciones por mayoría de votos:

$$\hat{y} = \text{mode}\{h_t(\mathbf{x})\}_{t=1}^T \quad (2)$$

3.4.3. XGBoost

Gradient boosting optimizado [4]. Minimiza una función objetivo regularizada:

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (3)$$

3.4.4. Gradient Boosting

Boosting clásico con 100 estimadores, construyendo cada árbol sobre los residuos del anterior para reducir sesgo iterativamente.

3.5. Fase 5 — Evaluación

Dado el desbalance de clases, se descartó la exactitud como métrica primaria. Las métricas utilizadas fueron:

- **ROC-AUC**: área bajo la curva ROC; mide el poder discriminativo del modelo de forma independiente al umbral.
- **Recall** ($= TP/(TP + FN)$): métrica principal de negocio; maximizar la detección de fraudes reales.
- **Precision** ($= TP/(TP + FP)$): proporción de alertas de fraude que son realmente fraude.
- **F1-Score**: media armónica de Precision y Recall.

4. Resultados

4.1. Análisis Exploratorio de Datos

La figura 1 muestra la distribución de clases; la figura 2 compara la distribución de **Amount** y **Time** por clase. La distribución del monto confirma que los fraudes se concentran en montos pequeños y medianos, posiblemente para evitar activar alertas automáticas basadas en umbral de monto.




Figura 1: Distribución de clases en el dataset (escala logarítmica).




Figura 2: Distribución de Amount y Time por clase.




Figura 3: Mapa de correlación entre variables numéricas del dataset.

4.2. Comparación de Modelos

La tabla 4 presenta las métricas de todos los modelos evaluados sobre el conjunto de prueba (sin balancear, representativo del mundo real).

Cuadro 4: Comparación de métricas de clasificación — conjunto de prueba

Modelo	ROC-AUC	Precision	Recall	F1-Score
Regresión Logística	0.9698	0.5217	0.0612	0.1094
Random Forest	0.9841	0.8404	0.8061	0.8229
XGBoost	0.9792	0.7878	0.8163	0.8018
Gradient Boosting	0.9807	0.1055	0.8980	0.1888

Conclusión: [Describir cuál fue el mejor modelo y por qué según las métricas. Mencionar la diferencia con la Regresión Logística como baseline. Indicar si el trade-off Precision/Recall fue favorable.]

4.3. Curvas ROC

La figura 4 muestra las curvas ROC para los cuatro modelos. [Describir qué modelos dominan en qué rango de FPR y qué implica para el umbral de decisión en producción.]




Figura 4: Curvas ROC — comparación de los cuatro modelos de clasificación.

4.4. Matriz de Confusión del Mejor Modelo

La figura 5 presenta la matriz de confusión del modelo con mayor ROC-AUC.




Figura 5: Matriz de confusión — mejor modelo ().

Cuadro 5: Descomposición de la matriz de confusión — mejor modelo

Métrica		Valor
Verdaderos Negativos (TN)		56,845
Falsos Positivos (FP)		19
Falsos Negativos (FN)		19
Verdaderos Positivos (TP)		79
Recall clase fraude		0.8061
Precision clase fraude		0.8404

Conclusión: Los falsos negativos (fraudes no detectados) son el error de mayor costo para el negocio. [Cuantificar cuántos fraudes del total el modelo logra detectar y qué porcentaje se escapa.]

4.5. Variables Más Influyentes

[Incluir gráfica de importancia de features si el mejor modelo es Random Forest, XG-Boost o Gradient Boosting. Comentar si V_{14} , V_{17} y V_{12} aparecen en el top 5, consistente con el análisis de correlación.]




Figura 6: Importancia de variables — mejor modelo ().

5. Discusión General

Los resultados muestran que SMOTE fue determinante para mejorar el Recall de la clase fraude: sin sobremuestreo, los modelos tienden a maximizar la exactitud global (que es trivialmente alta dado el desbalance) a costa de ignorar los fraudes. La aplicación de SMOTE solo al conjunto de entrenamiento garantiza que la evaluación se realice sobre la distribución real del problema.

Una limitación metodológica relevante es que las 28 componentes PCA del dataset están anonimizadas, lo que impide interpretar directamente el significado de negocio de las variables más influyentes. Esto limita la explicabilidad del modelo de cara a su adopción en producción.

La app Flask desarrollada permite ingresar los valores de V_1 – V_{28} , **Time** y **Amount** de una transacción nueva y obtener la predicción en tiempo real, junto con la probabilidad de fraude.

6. Conclusiones Finales

El análisis de detección de fraude sobre el dataset Credit Card Fraud Detection permite extraer cuatro conclusiones estructurales:

1. **SMOTE es imprescindible para datos con desbalance severo.** Sin sobre-muestreo, el Recall de la clase fraude colapsa hacia cero aunque la exactitud global sea superior al 99 %.
2. **El mejor modelo fue Random Forest con ROC-AUC de 0.9841 y Recall de 0.8061.** Los modelos ensemble (Random Forest, XGBoost, Gradient Boosting) superaron consistentemente a la Regresión Logística, lo que confirma la no-linealidad del problema.
3. **Las variables V_{14} , V_{17} y V_{12} son los predictores más informativos.** Su presencia dominante en la importancia de features es consistente con el análisis de correlación previo al modelado.
4. **El trade-off Precision/Recall debe calibrarse según el costo de negocio.** En el contexto bancario, un falso negativo (fraude no detectado) es más costoso que un falso positivo (alerta innecesaria), justificando umbrales de decisión inferiores a 0,5.

Referencias

- [1] Kaggle. (2013). *Credit Card Fraud Detection*. ULB Machine Learning Group. <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
- [2] Dal Pozzolo, A., Caelen, O., Le Borgne, Y.-A., Waterschoot, S., & Bontempi, G. (2015). Learned lessons in credit card fraud detection from a practitioner perspective. *Expert Systems with Applications*, 41(10), 4915–4928.
- [3] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMO-TE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.
- [5] The Nilson Report. (2021). *Issue 1209*. HSN Consultants.
- [6] Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *4th Int. Conf. on Practical Applications of Knowledge Discovery and Data Mining*.