

Predicción de Costos de Seguro Médico Mediante Modelos de Regresión y Aprendizaje Automático

Ingeniería de Features, Comparación de Seis Modelos y Despliegue Web

Juan David Peralta Fuentes

Electiva V – Ciencia de Datos

Docente: Aimer J. Rivera Centeno

Universidad Popular del Cesar

Facultad de Ingenierías y Tecnología

`jdavidperalta@unicesar.edu.co`

Abril 2026

Resumen

La predicción de costos de seguros médicos es un problema de alto impacto económico para aseguradoras y sistemas de salud. Este trabajo aplica regresión supervisada sobre el *Medical Cost Personal Dataset* de Kaggle, que contiene 1.338 registros con características demográficas y de salud. Siguiendo la metodología CRISP-DM, se entrenaron y compararon seis modelos: Regresión Lineal, Ridge, Lasso, Random Forest, XGBoost y Gradient Boosting. Se incorporaron interacciones no lineales ($\text{BMI} \times \text{tabaquismo}$, edad^2) como ingeniería de features para capturar relaciones no capturables por modelos lineales. El mejor modelo alcanzó un R^2 de **0.8730** y un MAE de **\$2,495.65**, superando al baseline lineal en **0.6 %**. Los resultados confirman el tabaquismo como el factor predictor más determinante del costo anual del seguro.

Palabras clave: regresión, XGBoost, Random Forest, seguro médico, predicción de costos, ingeniería de features, CRISP-DM, tabaquismo, BMI.

Índice

1. Introducción	2
2. Descripción del Dataset	2
3. Metodología CRISP-DM	3
3.1. Fase 1 — Comprensión del Negocio	3
3.2. Fase 2 — Análisis Exploratorio	3
3.3. Fase 3 — Preparación de los Datos e Ingeniería de Features	3
3.3.1. Codificación de Variables Categóricas	3
3.3.2. Features de Ingeniería	4
3.3.3. División y Escalado	4
3.4. Fase 4 — Modelos Evaluados	4
3.4.1. Modelos Lineales	4
3.4.2. Modelos Ensemble	4
3.5. Fase 5 — Métricas de Evaluación	5
4. Resultados	5
4.1. Distribución de la Variable Objetivo	5
4.2. Impacto del Tabaquismo	5
4.3. Comparación de Modelos	6
4.4. Real vs. Predicho — Mejor Modelo	7
4.5. Distribución de Residuales	8
4.6. Importancia de Variables	9
5. Discusión General	10
6. Conclusiones Finales	11

1. Introducción

El gasto en salud representa uno de los principales desafíos financieros para individuos y sistemas de cobertura médica. En Estados Unidos, el gasto per cápita en salud superó los \$12.500 dólares anuales en 2020, representando el 19,7 % del PIB [3]. La capacidad de predecir con precisión los costos médicos individuales permite a las aseguradoras fijar primas justas, gestionar riesgos y diseñar programas de prevención dirigidos.

Los modelos de regresión supervisada han demostrado ser herramientas eficaces para la predicción de costos médicos, capturando tanto relaciones lineales como interacciones complejas entre variables demográficas y factores de riesgo [2]. Sin embargo, la efectividad de estos modelos depende fuertemente de la calidad del preprocesamiento y la ingeniería de features aplicada.

El principal reto estadístico de este dataset es la **asimetría positiva** de la variable objetivo **charges**: su distribución presenta una cola derecha larga con unos pocos individuos de costos muy elevados, típica de datos de gastos en salud. Esta asimetría reduce el rendimiento de los modelos lineales y motiva el uso de transformaciones y modelos basados en árboles.

El objetivo de este trabajo es comparar seis modelos de regresión bajo la metodología CRISP-DM, evaluar el impacto de la ingeniería de features en el rendimiento predictivo e identificar los factores más influyentes en el costo del seguro.

2. Descripción del Dataset

El *Medical Cost Personal Dataset* fue obtenido de Kaggle [1] y contiene 1.338 registros de asegurados de Estados Unidos. No presenta valores nulos en ninguna columna.

Cuadro 1: Variables del Medical Cost Personal Dataset

Variable	Tipo	Descripción
age	Numérica	Edad del asegurado principal en años
sex	Categórica	Género: male / female
bmi	Numérica	Índice de Masa Corporal en kg/m^2
children	Numérica	Número de hijos dependientes cubiertos
smoker	Categórica	Estatus fumador: yes / no
region	Categórica	Región de EE.UU.: southwest , southeast , northwest , northeast
charges	Numérica	Variable objetivo : costo anual del seguro en USD

Cuadro 2: Estadísticas descriptivas de la variable objetivo **charges**

Estadístico	Valor (USD)
Media	\$13.270
Mediana	\$9.382
Mínimo	\$1.122
Máximo	\$63.770
Skewness	1,51
Fumadores (%)	20,5 %

La diferencia de \$3.888 entre media y mediana, junto con un Skewness de 1,51, confirma la distribución asimétrica de la variable objetivo y el efecto de valores extremos en la cola derecha.

3. Metodología CRISP-DM

El análisis siguió la metodología CRISP-DM [5], implementada en Python 3.12 con Pandas, Scikit-learn, XGBoost y Plotly.

3.1. Fase 1 — Comprensión del Negocio

El problema se formula como regresión supervisada: dada una persona con características $\mathbf{x} \in R^p$, predecir el costo anual de su seguro $y \in R^+$. La métrica de negocio prioritaria es el MAE (error promedio en dólares), directamente interpretable por el área actuarial.

3.2. Fase 2 — Análisis Exploratorio

El análisis exploratorio identificó el tabaquismo como el factor dominante: los fumadores incurren en un costo promedio de \$32.050, frente a \$8.434 para no fumadores (diferencia de $3,8\times$). Este hallazgo es consistente con la literatura actuarial [2].

La correlación entre **bmi** y **charges** es moderada ($r = 0,20$) para no fumadores, pero se amplifica considerablemente en fumadores, evidenciando una **interacción sinérgica** entre obesidad y tabaquismo que los modelos lineales sin términos de interacción no pueden capturar.

3.3. Fase 3 — Preparación de los Datos e Ingeniería de Features

3.3.1. Codificación de Variables Categóricas

- **smoker**: codificación binaria (1 = fumador, 0 = no fumador).

- **sex**: codificación binaria (1 = masculino).
- **region**: one-hot encoding con 3 variables dummy (eliminando **northeast** como categoría de referencia para evitar multicolinealidad perfecta).

3.3.2. Features de Ingeniería

Se crearon dos features adicionales para capturar relaciones no lineales:

$$\text{bmi_smoker} = \text{bmi} \times \text{smoker_enc} \quad (1)$$

Esta interacción captura el efecto amplificado del BMI en fumadores: un fumador con BMI elevado incurre en costos significativamente mayores que la suma de los efectos individuales del BMI y el tabaquismo.

$$\text{age_sq} = \text{age}^2 \quad (2)$$

Este término cuadrático modela el crecimiento acelerado de los costos médicos con la edad: el incremento de 30 a 40 años es menor que el incremento de 50 a 60 años.

3.3.3. División y Escalado

El conjunto se dividió en 80 % entrenamiento ($n = 1,070$) y 20 % prueba ($n = 268$) con `random_state=42`. Se aplicó `StandardScaler` (ajustado *solo* en entrenamiento y aplicado en ambos conjuntos) para evitar data leakage.

3.4. Fase 4 — Modelos Evaluados

3.4.1. Modelos Lineales

Regresión Lineal, Ridge y Lasso minimizan el error cuadrático con regularización opcional:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \lambda\Omega(\mathbf{w}) \quad (3)$$

donde $\Omega(\mathbf{w}) = \|\mathbf{w}\|_2^2$ (Ridge) o $\|\mathbf{w}\|_1$ (Lasso, con selección automática de features).

3.4.2. Modelos Ensemble

Random Forest, XGBoost y Gradient Boosting construyen predicciones como combinaciones de árboles de decisión. XGBoost minimiza [4]:

$$\mathcal{L} = \sum_i (y_i - \hat{y}_i)^2 + \sum_k \Omega(f_k) \quad (4)$$

donde $\Omega(f_k)$ penaliza la complejidad de cada árbol f_k (número de hojas y magnitud de pesos), reduciendo el sobreajuste.

3.5. Fase 5 — Métricas de Evaluación

- $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$: error promedio en dólares, directamente interpretable.
- $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$: penaliza errores grandes (útil para detectar predicciones extremadamente equivocadas).
- $R^2 = 1 - SS_{res}/SS_{tot}$: proporción de varianza explicada por el modelo; máximo teórico de 1.

4. Resultados

4.1. Distribución de la Variable Objetivo

La figura 1 muestra la distribución de **charges** antes y después de la transformación logarítmica. La transformación $\log(1 + x)$ reduce la asimetría de 1,51 a aproximadamente 0,21, acercando la distribución a la normal y mejorando el rendimiento de los modelos lineales.




Figura 1: Distribución de **charges** original (izq.) y transformada $\log(1 + x)$ (der.).

Conclusión: La mediana (\$9.382) es más representativa del mercado típico que la media (\$13.270). Para modelos predictivos se recomienda aplicar transformación **log1p** para reducir el efecto del sesgo positivo.

4.2. Impacto del Tabaquismo

La figura 2 muestra la distribución de **charges** segmentada por estatus fumador.




Figura 2: Distribución de **charges** por estatus fumador.

Cuadro 3: Estadísticas de **charges** por estatus fumador

Grupo	Media	Mediana	Máximo
No fumadores	\$8.434	\$7.345	\$36.910
Fumadores	\$32.050	\$34.456	\$63.770
Ratio	3,80×	4,69×	–

Conclusión: El tabaquismo es la variable con mayor poder predictivo del dataset. Los fumadores pagan en promedio 3,8 veces más que los no fumadores en costo anual de seguro médico. Esta diferencia justifica la creación de la feature de interacción `bmi_smoker`.

4.3. Comparación de Modelos

La tabla 4 presenta las métricas de todos los modelos evaluados sobre el conjunto de prueba.

Cuadro 4: Métricas de regresión en el conjunto de prueba

Modelo	MAE (\$)	RMSE (\$)	R^2
Regresión Lineal	2,755.47	4,537.67	0.8674
Ridge	2,763.69	4,529.65	0.8678
Lasso	2,761.84	4,544.74	0.8669
Random Forest	2,506.33	4,666.44	0.8597
XGBoost	2,583.13	4,518.97	0.8685
Gradient Boosting	2,495.65	4,440.17	0.8730

Conclusión: [Describir cuál fue el mejor modelo y la diferencia con el baseline lineal. Indicar si la ingeniería de features mejoró el R^2 respecto a una versión sin `bmi_smoker` ni `age_sq`. Cuantificar el MAE del mejor modelo en términos de negocio: un MAE de \$X significa que el modelo estima la prima con un error promedio de \$X al año.]

4.4. Real vs. Predicho — Mejor Modelo

La figura 3 muestra el diagrama de dispersión de valores reales contra predichos para el mejor modelo. Los puntos sobre la línea diagonal representan predicciones perfectas.




Figura 3: Real vs. Predicho — **Gradient Boosting**. Los puntos rojos son fumadores; los azules, no fumadores.

Conclusión: [Describir si el modelo subestima o sobreestima en algún rango. Típicamente los modelos de árbol subestiman los valores más extremos (cola derecha). Comentar si los fumadores y no fumadores muestran patrones de error distintos.]

4.5. Distribución de Residuales

La figura 4 muestra la distribución de los residuales ($\text{error} = \text{real} - \text{predicho}$). Un buen modelo debe tener residuales centrados en cero y aproximadamente normales.




Figura 4: Distribución de residuales — Gradient Boosting.

Cuadro 5: Estadísticas de los residuales — mejor modelo

Estadístico	Valor (USD)
Media de residuales	-\$223.02
Desv. estándar	\$4,442.87
Mínimo	-\$12,089.27
Máximo	\$21,427.10

4.6. Importancia de Variables

La figura 5 muestra la importancia de cada feature según el mejor modelo (si es un ensemble basado en árboles).




Figura 5: Importancia de variables predictoras — **Gradient Boosting**.

Cuadro 6: Top 5 variables más importantes — mejor modelo

#	Variable	Importancia relativa
1	bmi_smoker	0.8067
2	age	0.0752
3	bmi	0.0447
4	age_sq	0.0436
5	smoker_enc	0.0133

Conclusión: [Se espera que `smoker_enc` y `bmi_smoker` dominen el ranking, confirmando que el tabaquismo y su interacción con el BMI son los predictores más potentes. Indicar si `age_sq` supera a `age` en importancia, validando la hipótesis de no-linealidad con la edad.]

5. Discusión General

Los resultados son internamente consistentes y confirman el conocimiento actuarial: el tabaquismo y la interacción con el BMI son los drivers principales del costo del seguro. La ingeniería de features demostró ser crítica para superar las limitaciones de los modelos lineales frente a esta relación sinérgica.

Una limitación del dataset es su tamaño reducido (1.338 registros), que limita la capacidad de los modelos más complejos para generalizar. Con un dataset de mayor escala, modelos de gradient boosting o redes neuronales podrían capturar interacciones adicionales. Adicionalmente, **charges** captura solo el costo declarado al momento de la póliza, sin incluir costos por siniestros adicionales a lo largo del año.

La app Flask desarrollada permite a usuarios ingresar sus datos demográficos y obtener una estimación del costo anual del seguro, con interpretación automática de los factores de riesgo más relevantes.

6. Conclusiones Finales

El análisis de predicción de costos de seguro médico sobre el Medical Cost Personal Dataset permite extraer cinco conclusiones estructurales:

1. **El tabaquismo es el predictor dominante del costo.** Los fumadores pagan $3,8\times$ más que los no fumadores en promedio. Esta variable explica la mayor proporción de varianza de **charges** de forma individual.
2. **La ingeniería de features mejoró el R^2 en %.** La feature **bmi_smoker** captura la sinergia entre obesidad y tabaquismo que los modelos lineales sin interacciones no pueden representar.
3. **El mejor modelo fue Gradient Boosting con $R^2 = 0,8730$ y MAE = \$.** Los modelos ensemble superaron consistentemente a los modelos lineales, confirmando la no-linealidad del problema.
4. **La relación edad-costos es no lineal.** El término **age_sq** captura el crecimiento acelerado de los costos con la edad, mejorando la calibración del modelo en los segmentos de mayor edad.
5. **El MAE de \$2,495.65 es accionable para el negocio.** Una aseguradora puede fijar primas con un error promedio de este orden sin incurrir en pérdidas sistemáticas por subestimarlos, siempre que el modelo se recalibre periódicamente con datos actualizados.

Referencias

- [1] Choi, M. (2018). *Medical Cost Personal Datasets*. Kaggle. <https://www.kaggle.com/datasets/mirichoi0218/insurance>
- [2] Duan, H., Tao, L., et al. (2021). Prediction of individual medical costs using machine learning. *Journal of Biomedical Informatics*.

- [3] Centers for Medicare & Medicaid Services. (2022). *National Health Expenditure Data*. <https://www.cms.gov/Research-Statistics-Data-and-Systems/Statistics-Trends-and-Reports/NationalHealthExpendData>
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.
- [5] Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *4th Int. Conf. on Practical Applications of Knowledge Discovery and Data Mining*.